

分類模型與電腦視覺評估指標筆記 (Classification & Computer Vision Metrics)

在機器學習（分類模型、醫療診斷）與電腦視覺（圖像分割、物件偵測）中，我們常用混淆矩陣（Confusion Matrix）及集合論衍生的各項指標來評估模型效能。



一、常見分類評估指標 (Classification Metrics)

1. AUC (Area Under the ROC Curve, ROC 曲線下面積)

- **定義：** ROC 曲線下方的總面積，用來衡量模型在不同判斷門檻（Threshold）下的整體**排序與區分能力**。
 - 本質上是：隨機抽一個正樣本與一個負樣本，模型給正樣本較高預測分數的機率——衡量的是「排序能力」，不是直接的分類正確率。
 - **評估標準：**
 - **AUC = 1.0**：完美分類模型。
 - **AUC = 0.5**：模型能力等同於隨機擲硬幣。
 - **AUC < 0.5**：預測方向相反（反轉預測結果即可提升）。
 - **注意：** AUC 相較 Accuracy 對類別比例較不敏感，但並非「完全不受影響」——在極度不平衡資料（如 9990 健康、10 生病）下，AUC 仍可能過度樂觀，無法反映模型實際找出少數類的能力，仍需搭配 PPV、Sensitivity 等指標一起看。
-

2. Accuracy (準確率)

- **定義：** 在**所有**預測樣本中，模型猜對的比例（包含正確猜對正類與負類）。
- **公式：**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **優缺點：** 最直覺，但在**資料極度不平衡**時會失真（例如：99 個健康、1 個生病，模型全部猜健康也有 99% 的 Accuracy）。
-

3. Sensitivity (敏感度 / Recall 召回率 / True Positive Rate, TPR)

- **定義：** 在所有 **實際為正類（如：真的有病）** 的樣本中，模型成功抓出的比例。
- **公式：**

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

- **應用場景：** 適用於「**寧可錯殺，不可放過**」的情境（如：癌症篩檢、信用卡盜刷檢測，絕不能漏掉正類）。
-

4. Specificity (特異度 / True Negative Rate, TNR)

- **定義**：在所有 **實際為負類（如：真的健康）** 的樣本中，模型成功認出（判斷為陰性）的比例。
- **公式**：

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **應用場景**：特異度高代表模型 **不容易報假警**（例如：不會輕易把健康的人誤診為癌症）。
-

5. F1-Score (F1 分數) / Dice Coefficient (Dice 相似係數)

- **定義**：精確率 (PPV / Precision) 與敏感度 (Sensitivity / Recall) 的**調和平均數 (Harmonic Mean)**。在圖像分割 (Segmentation) 領域稱為 **Dice 系數** (數學上完全等價)。
- **公式**：

$$\text{F1-Score} = 2 \times \frac{\text{PPV} \times \text{Sensitivity}}{\text{PPV} + \text{Sensitivity}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

$$\text{Dice} = \frac{2|\text{Predicted} \cap \text{Target}|}{|\text{Predicted}| + |\text{Target}|}$$

- **優缺點**：數值介於 0 ~ 1 之間，越接近 1 越好。能綜合評估捕捉能力與準確度，在**類別不平衡**時比 Accuracy 更具參考價值。
 - **注意**：F1 = Dice 的等價關係，前提是**二元分割 (binary segmentation)** 且以 **pixel 為樣本單位** 計算。若是 **multi-class segmentation** (如 background / cat / dog)，通常改採 **per-class Dice** 再取 **mean Dice**，而非單一 F1 值。
-

6. PPV (Positive Predictive Value, 陽性預測值 / Precision 精確率)

- **定義**：在所有被模型 **判定為陽性 (預測有病)** 的樣本中，實際真的為陽性的比例。
- **公式**：

$$\text{PPV} = \frac{TP}{TP + FP}$$

- **特點**：站在「預測結果」的角度思考。關注的是模型警報的準確度（出錯/誤報的代價高不高）。受資料盛行率 (Prevalence) 影響極大。
-

7. NPV (Negative Predictive Value, 陰性預測值)

- **定義**：在所有被模型 **判定為陰性 (預測健康)** 的樣本中，實際真的為陰性的比例。
- **公式**：

$$\text{NPV} = \frac{TN}{TN + FN}$$

- **特點**：當模型告訴使用者「沒問題/陰性」時，使用者可以安心的程度（漏報的代價高不高）。
-

8. FPR (False Positive Rate, 假陽性率 / 誤報率)

- **定義**：在所有 **實際為負類（如：真的健康）** 的樣本中，被模型誤診為陽性（有病）的比例。

- 公式：

$$FPR = \frac{FP}{FP + TN} = 1 - \text{Specificity}$$

- 特點：越低越好（希望接近 0）。此指標即為 ROC 曲線的 X 軸。
-

9. FNR (False Negative Rate, 假陰性率 / 漏報率)

- 定義：在所有 **實際為正類（如：真的有病）** 的樣本中，被模型漏抓/誤判為陰性的比例。
- 公式：

$$FNR = \frac{FN}{TP + FN} = 1 - \text{Sensitivity}$$

- 特點：越低越好，代表模型不漏抓。
-

10. MCC (Matthews Correlation Coefficient, 馬修斯相關係數)

- 定義：考量混淆矩陣所有四個象限 (TP, TN, FP, FN) 的綜合相關係數。
- 公式：

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

- 特點：範圍為 $-1 \sim +1$ ($+1$ 為完美預測、 0 為沒有相關、 -1 為完全反向)。是在**類別極度不平衡**資料下相當穩健的單一評估指標之一（而非「最客觀」的唯一指標——不同任務仍有各自偏好的指標，如醫療篩檢重 Sensitivity、垃圾郵件重 Precision、分割重 Dice/IoU、極度不平衡分類也常搭配 PR-AUC 一起看）。
-

二、圖像與視覺特有指標 (Computer Vision Metrics)

在目標檢測 (Object Detection) 與圖像分割 (Segmentation) 領域，經常以集合 (Set) 的方式來表示遮罩 (Mask) 或邊界框 (Bounding Box) 的重疊程度：

1. IoU (Intersection over Union, 交併比 / Jaccard Index)

- 定義：預測區域與真實區域 (Ground Truth) 的**交集面積除以併集面積**。
- 公式：

$$IoU = \frac{|\text{Predicted} \cap \text{Target}|}{|\text{Predicted} \cup \text{Target}|} = \frac{TP}{TP + FP + FN}$$

- 注意：此處 TP/FP/FN 是指空間區域(pixel 或 box)重疊關係。
- 應用場景：Object Detection 中用於計算 **預測框與 Ground Truth 框** 的重疊程度；Segmentation 中則用於計算 **遮罩 (Mask)** 重疊程度。

2. Dice 與 IoU 的互相轉換

- $\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}}$

- $\text{IoU} = \frac{\text{Dice}}{2 - \text{Dice}}$

3. PR Curve (Precision-Recall Curve) 與 AP / mAP

- **PR Curve**: 以 Recall 為橫軸、Precision 為縱軸，觀察不同門檻下兩者的取捨關係。PR Curve 在正類稀少 (positive class rare) 的情況下，通常比 ROC Curve 更能反映模型對少數類的辨識能力。
- **AP (Average Precision)**: AP 是根據 Precision-Recall 曲線計算的單一類別評估指標，用來衡量模型在不同 Recall 下的 Precision 表現，常用於 Object Detection 評估。
- **mAP (mean Average Precision)**: 對所有類別的 AP 取平均，YOLO、Faster R-CNN 等物件偵測模型的標準評估指標。

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i$$

其中:

- N : 類別數量
- AP_i : 第 i 類別 AP
- **常見寫法**: $\text{AP}@0.5$ (IoU 門檻 0.5 時的 AP)、 $\text{AP}@0.5:0.95$ (IoU 門檻從 0.5 到 0.95、間隔 0.05 取平均, COCO 標準評估方式)。

⚡ 三、錯誤類型 (Error Types)

兩型錯誤 (Type I & Type II Errors)

- **FP (假陽性 / 誤報) $\approx$ 類似第一型錯誤 (Type I Error)**
 - 沒事報有事 (如: 健康者被診斷有病、正常信件被當作垃圾郵件)。
- **FN (假陰性 / 漏報) $\approx$ 類似第二型錯誤 (Type II Error)**
 - 有事報沒事 (如: 癌症患者被診斷健康、不良品被放行)。通常代價極高甚至致命。

⚠ **注意**: 嚴格來說，統計假設檢定中的 Type I / II Error 是定義在「拒絕 / 不拒絕 H_0 」的框架下，與分類問題的 FP / FN 並非完全對等，兩者僅為**類比關係** (結構相似)，使用時不宜直接畫等號。

📈 四、什麼是 ROC 曲線? (ROC Curve)

ROC 全名為 **Receiver Operating Characteristic Curve (接收者操作特徵曲線)**，是一張用來評估分類模型在不同機率門檻 (Threshold) 下表現的二維圖表。

1. ROC 曲線的座標軸

- **橫軸 (X 軸): 假陽性率 (False Positive Rate, FPR)**
 - 公式: $\text{FPR} = 1 - \text{Specificity} = \frac{FP}{TN + FP}$
 - 意義: 沒病卻被誤判成有病的比例 (越低越好, 希望接近 0)。
- **縱軸 (Y 軸): 真陽性率 (True Positive Rate, TPR / Sensitivity)**
 - 公式: $\text{TPR} = \text{Sensitivity} = \frac{TP}{TP + FN}$
 - 意義: 真的有病且被成功抓出來的比例 (越高越好, 希望接近 1)。

2. 判讀方式

- **最佳點 (0, 1)**: 位於圖表左上角，代表零誤判 ($FPR = 0$) 且全抓到 ($TPR = 1$)。曲線越往左上角靠攏，模型越優秀。
- **對角線 (0,0) -> (1,1)**: 代表「隨機猜測」(猜對猜錯機率各半)。曲線若落在這條線上，代表模型完全無預測能力。

3. Threshold 對模型表現的影響

分類模型通常輸出一個介於 0 到 1 的預測機率，透過 Threshold 將機率轉換為 Positive / Negative 類別。

降低分類 Threshold:

- 預測 Positive 數量增加
- TP 增加
- FP 增加
- FN 減少
- TN 減少

因此:

- Sensitivity $\uparrow$
- Recall $\uparrow$
- Specificity $\downarrow$
- Precision 可能下降

不同 Threshold 會產生不同的 Confusion Matrix，因此也會產生不同的 TPR、FPR、Precision 與 Recall。ROC Curve 與 PR Curve 即是利用不同 Threshold 下的結果來評估模型整體表現。

模型實務上通常需依照任務需求選擇最佳 Threshold。



 五、指標速查對照表

指標	觀察視角 / 關注焦點	適用情境 / 特點
ROC / AUC	不同 threshold 下的排序與區分能力	跨模型比較常用;相較 Accuracy 對類別比例較不敏感，但極端不平衡時仍需搭配其他指標
Accuracy	全局猜對比例	資料平衡時使用
Sensitivity (Recall)	站在 真實患者 角度 (抓出率)	醫療診斷、安檢 (寧可錯殺，不可放過)
Specificity	站在 真實健康者 角度 (辨識率)	避免誤診、品質抽檢 (減少假警報)
F1-Score / Dice	兼顧 Precision 與 Recall	類別不平衡資料、圖像分割 (Segmentation)，尤其適合正類稀少的 binary classification 或 segmentation
PPV (Precision)	站在 模型猜陽性 的角度 (準確率)	廣告點擊率、垃圾郵件 (警報必須準)

指標	觀察視角 / 關注焦點	適用情境 / 特點
NPV	站在 模型猜陰性 的角度 (安心度)	評估排除疾病或風險的可靠度
FPR	站在 真實健康者 角度 (誤報率)	評估亂報警程度, ROC 曲線的 X 軸
FNR	站在 真實患者 角度 (漏報率)	評估漏診程度
MCC	綜合四個象限的極端平衡	嚴苛評估極度不平衡資料時的重要指標之一
IoU (Jaccard)	重疊面積占比	物件偵測 (Object Detection) 、圖像分割

六、混淆矩陣結構 (Confusion Matrix)

1. 表格結構

	預測 Positive (陽性)	預測 Negative (陰性)
實際 Positive	TP (True Positive, 真陽)	FN (False Negative, 假陰 / 類似 Type II Error)
實際 Negative	FP (False Positive, 假陽 / 類似 Type I Error)	TN (True Negative, 真陰)

判讀口訣：

- 第一個字看**對錯** (True 代表猜對, False 代表猜錯) 。
- 第二個字看**模型猜什麼** (Positive 代表猜正類, Negative 代表猜負類) 。

2. 實務觀念：門檻調校與正規化

- **分類閾值 (Threshold)**：混淆矩陣的數值會隨判定門檻改變。降低門檻時 (如由 0.5 降至 0.2) ，通常會使更多樣本被判為 Positive，因此 **TP 與 FP 傾向增加**，**FN 與 TN 傾向減少** (提升 Sensitivity, 降低 Specificity) 。
- **正規化混淆矩陣 (Normalized Confusion Matrix)**：當正負樣本數量懸殊時，將矩陣轉換為比例/百分比 (0.0 ~ 1.0) ，有助於更客觀地比較不同類別的辨識表現。